

Relatório de Laboratório

Laboratório de Experimentação de Software — Lab02: assistentes de IA versus codificação manual

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor(a)	Danilo Maia
Laboratório	Lab02 — Assistentes de IA versus codificação manual
Grupo (trio)	Víctor Gabriel Cruz Pereira · Jonathan Sena da Silva · Matheus Fernandes de Oliveira
Link do repositório / GitHub Projects	https://github.com/Victorgabrielcruz/lab-medicao-e-experimentacao-de-software · https://github.com/users/Victorgabrielcruz/projects/6/views/1
Data de entrega	24/09/2026 — primeira versão completa

1. Introdução

Assistentes de IA generativa passaram a fazer parte do fluxo de desenvolvimento de software, mas seu efeito depende da tarefa, da pessoa, do modelo e das condições de uso. Este laboratório investigou, em um cenário controlado de katas curtas, como a resolução com assistente de IA se compara à codificação manual em tempo, qualidade funcional e características estruturais do código. O objetivo não é estimar um efeito universal da IA, mas documentar de forma reproduzível o que ocorreu nos trials registrados pelo grupo.

O estudo responde às três questões de pesquisa pré-registradas em `Docs/methodology.md` (../Docs/methodology.md):

- **RQ1 — Tempo:** o uso de assistente de IA reduz o tempo necessário para resolver uma tarefa de programação?
- **RQ2 — Defeitos:** o uso de assistente de IA aumenta a taxa de testes de aceitação passando ao fim do trial?
- **RQ3 — Estrutura:** o uso de assistente de IA altera a complexidade ciclomática ou a duplicação do código produzido?

As hipóteses foram definidas antes da execução. Para RQ1, **H0₁** afirma que a mediana de $T_manual - T_IA$ é zero, e **H1₁** que ela é maior que zero. Para RQ2, **H0₂** afirma que a mediana de $S_IA - S_manual$ é zero, e **H1₂** que ela é maior que zero. Para RQ3, as hipóteses são bicaudais: **H0_{3a}/H0_{3b}** afirmam que as medianas de $CC_IA - CC_manual$ e de $DUP_IA - DUP_manual$ são zero; **H1_{3a}/H1_{3b}** afirmam que são diferentes de zero. As direções são importantes: diferença positiva em RQ1 favorece IA; em RQ2 e RQ3, ela indica maior valor com IA.

2. Contexto

O Lab02 foi executado por três estudantes de graduação identificados, nas análises, como P01, P02 e P03. Cada participante realizou seis trials em seis katas inéditas, organizadas em três blocos de dificuldade equivalente: B1 (K01/K02), B2 (K03/K04) e B3 (K05/K06). Cada bloco fornece um par: uma kata sob tratamento IA e a outra sob tratamento Manual. O desenho é, portanto, **crossover within-subject**, com nove comparações participante × bloco e 18 trials no total.

A alocação foi congelada em 10/09/2026 com a semente 20260910. O plano contrabalanceou a sequência de tratamentos; a ordem efetivamente executada foi registrada para não ocultar desvios.

Participante	Sequência planejada de tratamentos	Ordem efetiva das katas
P01	IA → Manual → IA → Manual → IA → Manual	1 → 4 → 5 → 3 → 2 → 6
P02	Manual → IA → Manual → IA → Manual → IA	1 → 3 → 5 → 4 → 2 → 6
P03	IA → Manual → Manual → IA → IA → Manual	1 → 2 → 3 → 4 → 5 → 6

O time-box foi de 35 minutos (2.100 s) por trial. Um trial que alcançasse o limite deveria permanecer no dataset como censurado, com tempo observado de 2.100 s; nenhum dos 18 trials oficiais foi censurado. Pausas registradas ficaram abaixo de 15 minutos. O dataset mantém a cadeia `Issue → trial_id →`

commit → dados brutos → dataset processado → análise/figura, o que permite localizar o `trial.json`, o JUnit final, as métricas estáticas e o código preservado de cada observação.

3. Metodologia

3.1 Principais desafios

- **Disponibilidade desigual de métricas estruturais.** Oito trials não têm métricas de LOC, complexidade, duplicação e manutenibilidade; assim, RQ3 tem 10/18 observações de tratamento e apenas 4/9 pares completos. Essas lacunas foram preservadas como ausentes, sem imputação e sem conversão para zero.
- **Conflito de evidências em P01-K02-manual.** O JUnit final bruto registra 0/5, enquanto o `poll` documentado registra 5/5 a 884,796 s. A nota de qualidade preservada explica a condição de corrida do coletor; o dataset oficial utiliza 5/5, mas a ressalva permanece explícita no relatório.
- **Aderência parcial ao tratamento planejado.** O protocolo pré-registrou Codex CLI, mas cinco trials IA usaram Claude e quatro usaram Codex. Há também desvios de versão e registros de prompts não exportáveis. Esses fatos reduzem a capacidade de atribuir resultados a um único modelo.
- **Amostra pequena e dependência entre pares.** Nove pares vêm de apenas três participantes; os pares de uma mesma pessoa não são independentes. Por isso, valores de p e intervalos são apresentados como evidência exploratória, complementados por uma análise de sensibilidade com uma mediana por participante.

3.2 Tomadas de decisão

- A unidade experimental é um **trial**: uma pessoa, uma kata, um tratamento e um limite de tempo. A comparação pareada usa participante e bloco de dificuldade, não a mesma kata repetida.
- `duration_seconds` mede tempo até todos os testes passarem; `success_rate = passed_tests / total_tests × 100` é a métrica funcional primária. Testes falhando são complementares.
- Para RQ3, a complexidade ciclomática média e a duplicação são confirmatórias; LOC é controle obrigatório e o Índice de Manutenibilidade (MI) é exploratório. Métricas ausentes excluem apenas o par daquela métrica.
- A análise usa Wilcoxon exato por permutação de sinais dos postos não nulos, com $\alpha = 0,05$. RQ1/RQ2 usam alternativa unilateral; RQ3 é bicaudal e ajusta complexidade/duplicação por Holm. Os ICs bootstrap de 95% são exploratórios.
- O outlier P02-K02-manual (1.191 s) foi mantido. A validação encontrou 0 erro crítico, 31 avisos e 1 observação extrema preservada; não houve limpeza manual dos valores que favorecessem uma hipótese.

3.3 Etapas

Etapa	Entrega rastreável	Evidência principal
Planejamento	protocolo, katas, blocos e alocação congelada	Docs/methodology.md, data/metadata/allocation.csv
Execução	18 registros de trial, código final e testes	data/raw/trials/, trials/
Consolidação	dataset único, erros e validação	data/processed/trials.csv, consolidation-errors.csv, reports/drafts/data-validation.md
Análise	RQ1–RQ3, resultados estatísticos e dashboard	scripts/run_analysis.py, scripts/generate_dashboard.py, reports/figures/dashboard/
Relatório final	tabela reproduzível, figuras e documento	scripts/generate_final_report_table.py, reports/final/

3.4 Ferramentas e ambiente

O ambiente planejado foi Python 3.12.14, pytest 9.1.1, Radon 6.0.1, JSCPD 5.2.0, Node 24.19.0, npm 11.17.0, uv 0.12.10 e VS Code 1.137.0. Para análise e visualização foram usados SciPy 1.16.2, Matplotlib 3.10.6 e Streamlit 1.64.0. As versões, configurações e dependências permanecem em `data/metadata/environment.json`, `requirements*.txt`, `requirements.lock`, `radon.cfg` e `.jscpd.json`.

O tratamento IA pré-registrado foi Codex CLI 0.154.0, modelo `gpt-5.3-codex`, via ChatGPT Pro, em modo chat/agente pelo terminal, com acesso verificado em 10/09/2026 e contexto novo a cada trial. A execução real contém exceções: P01 usou Claude Code 2.1.273 com `claude-sonnet-5`; P02-K01-ai e P02-K04-ai também registram Claude, com versão esperada 2.1.273 e detectada 2.1.276. O relatório trata o tratamento como “uso de assistente de IA” e não como um efeito exclusivo de uma ferramenta.

3.5 Tabela de métricas

RQ	Métrica	Definição operacional	Unidade	Fonte
RQ1	Tempo até verde	Tempo observado até todos os testes de aceitação passarem; 2.100 s se censurado	segundos	trial.json, logs e dataset consolidado
RQ2	Taxa de sucesso	$\text{passed_tests} / \text{total_tests} \times 100$ ao fim do trial	percentual	JUnit final, trial.json e nota de qualidade quando aplicável
RQ3	Complexidade média	Média da complexidade ciclomática por função/método	pontos	Radon em metrics.json
RQ3	Duplicação	Linhas duplicadas relativas ao código de produção final	percentual	JSCPD em metrics.json
RQ3	LOC e MI	Controles de tamanho e análise exploratória de manutenibilidade	linhas / pontos	metrics.json

3.6 Reprodutibilidade e contribuição técnica

O pipeline é executado da pasta Lab02 e não requer edição manual do dataset:

```
python scripts/build_dataset.py
python scripts/validate_dataset.py
python scripts/run_analysis.py
python scripts/generate_dashboard.py --dataset data/processed/trials.csv --output
reports/figures/dashboard
python scripts/generate_final_report_table.py --input data/processed/statistical-
results.csv --output-dir reports/final/figures
python scripts/generate_final_report_docx.py --template Docs/templates/
Template_Relatorio_Laboratorio.docx
```

O novo `scripts/generate_final_report_table.py` gera a Tabela 1 em CSV e Markdown diretamente de `data/processed/statistical-results.csv`; seus testes ficam em `tests/test_final_report_table.py`. O gerador do documento usa `python-docx==1.2.0` (fixado em `requirements-report.txt`) e a cópia versionada do template fornecido. As figuras selecionadas nesta versão são cópias rastreáveis das saídas do dashboard; suas fontes, nomes originais e geradores estão documentados em `figures/README.md` (`figures/README.md`).

4. Resultados

4.1 Coleta, cobertura e qualidade

O dataset oficial possui exatamente 18 linhas e 18 `trial_id` únicos: nove tratamentos IA e nove Manuais, todos concluídos. Há nove pares válidos para RQ1/RQ2, formados por P01–P03 e B1–B3. A validação de 23/09/2026 autorizou o uso do dataset nas três RQs, sem achado crítico. O relatório de consolidação de erros e os 31 avisos permanecem disponíveis; eles indicam limitações de cobertura, não dados fabricados.

Situação	Resultado	Tratamento no relatório
Trials censurados	0/18	nenhum valor foi artificialmente limitado; a regra de 2.100 s continua documentada
Métricas estruturais ausentes	8/18 trials; 4/9 pares completos	células vazias; exclusão somente da comparação estrutural correspondente
Dificuldade percebida	ausente em todos os trials	não analisada como desfecho
Logs de prompts	indisponíveis em 5 trials IA	ausência declarada; não inferida a partir de texto livre
Tentativas IA invalidadas	3 tentativas fora do dataset oficial	excluídas por falta de interação real documentada; possível exposição prévia é ameaça à validade
Outlier de tempo	P02-K02-manual, 1.191 s	mantido, identificado e não removido

Tabela 1 — Síntese quantitativa das RQs. A tabela foi produzida pelo script versionado e também está disponível em `figures/tabela-resumo-rqs.md` (figures/tabela-resumo-rqs.md) e `figures/tabela-resumo-rqs.csv` (figures/tabela-resumo-rqs.csv).

RQ	Métrica	Manual	IA	Comparação pareada / ressalva
RQ1	Tempo até todos os testes verdes	606 [485; 695] (n=9) s	261 [178; 316] (n=9) s	Δ Manual–IA=+310 s; $p=0,0098$; $r=0,87$; IC expl. [-92; 549] s; 9/9 pares, 0 ausente(s).
RQ2	Taxa de sucesso dos testes	100 [100; 100] (n=9) %	100 [100; 100] (n=9) %	Δ IA–Manual=0 p.p.; 9/9 empates; p e r indefinidos por empates totais; IC expl. [0; 0] p.p.; 0 ausente(s).
RQ3	Complexidade ciclomática média	8,00 [7,25; 9,00] (n=4) pontos	7,00 [7,00; 9,25] (n=6) pontos	Δ IA–Manual=+2,00 pontos; 4/9 pares; 5 ausente(s); $p=0,7500$; Holm=1,0000; $r=0,20$; IC expl. [-5; 4].
RQ3	Duplicação	0,00 [0,00; 0,00] (n=4) %	0,00 [0,00; 0,00] (n=6) %	Δ IA–Manual=0,00 p.p.; 4/4 empates; 5 ausente(s); p e r indefinidos por empates totais.
RQ3	LOC / manutenibilidade (exploratórias)	LOC 31,50; MI 63,60 (n=4)	LOC 33,50; MI 78,98 (n=6)	Métricas de controle/ exploratórias; 4/9 pares estruturais completos; sem teste confirmatório pré-registrado.

4.2 Visualizações e respostas objetivas

RQ1 — Tempo

Nos nove pares registrados, a mediana do tempo foi 606 s no tratamento Manual e 261 s no tratamento IA. A diferença pareada mediana Manual – IA foi +310 s; sete pares favoreceram IA. O Wilcoxon unilateral resultou em $p=0,0098$ e a correlação bisserial de postos foi 0,87, mas o intervalo exploratório de 95% foi amplo (–92 a 549 s). **Resposta à RQ1:** para os trials observados, IA esteve associada a menor tempo na maioria dos pares; isso não demonstra um efeito causal geral.




Figura 1 — RQ1: tempo por tratamento; cada ponto é um trial

RQ2 — Qualidade funcional

Os dois tratamentos tiveram mediana de 100% de sucesso, com nove diferenças pareadas iguais a zero; por isso, o teste de Wilcoxon e o tamanho de efeito ficam indefinidos por empates totais. **Resposta à RQ2:** não se observou diferença na taxa final de testes passando. O resultado não prova equivalência funcional nem ausência de defeitos fora da suíte de aceitação.

RQ2 · resultados individuais dos 18 trials




Figura 2 — RQ2: taxa de sucesso e conclusão nos 18 trials

RQ3 — Qualidade estrutural

Na complexidade ciclomática média, os quatro pares completos produziram diferenças IA – Manual de +4, +2, -5 e +2 pontos, com mediana +2. O teste bicaudal resultou em $p=0,7500$, Holm = 1,0000, $r=0,20$ e IC exploratório de -5 a 4 pontos. A duplicação foi 0% nos quatro pares completos, todos empatados. LOC mediano foi 31,50 no Manual e 33,50 com IA; MI mediano foi 63,60 e 78,98, respectivamente, mas ambas são leituras exploratórias em amostras marginais de tamanhos diferentes.

Resposta à RQ3: os dados disponíveis não sustentam uma alteração estrutural geral; a complexidade aponta +2 pontos com IA nos pares observáveis, com incerteza ampla e cobertura incompleta.




Figura 3 — RQ3: disponibilidade das métricas estruturais

4.3 Discussão

RQ1 — Interpretação do efeito de tempo

O efeito observacional em RQ1 é grande em direção favorável à IA: a diferença pareada mediana foi de 310 s e sete de nove pares apontaram para menor tempo com assistente. Ainda assim, a síntese por participante produz medianas de +302 s (P01), +549 s (P02) e -92 s (P03), com $p=0,25$ para apenas três resumos. Essa sensibilidade mostra que o resultado agregado não deve ser interpretado como uma estimativa independente de nove pessoas. Diferenças de experiência, ordem de execução, familiaridade com as katas e o próprio assistente podem explicar parte do contraste.

RQ2 — Teto funcional e evidência conflitante

O desfecho ficou no teto: 18/18 trials no dataset consolidado têm 100% de sucesso. Essa leitura é condicional à interpretação auditada de P01-K02-manual: o `poll` registrado em 884,796 s indica 5/5, enquanto o JUnit final bruto indica 0/5 e `NotImplementedError`. Se o JUnit final fosse usado isoladamente, haveria 17/18 verdes e um par favorável à IA. A decisão de consolidação é rastreável e não altera o arquivo bruto, mas torna RQ2 particularmente sensível à qualidade do coletor. Além disso, teste de aceitação não mede todos os defeitos possíveis.

RQ3 — Cobertura incompleta e magnitudes

RQ3 é a comparação mais limitada. Oito trials sem métricas estruturais reduzem a análise pareada a quatro pares, e P01 não possui nenhuma observação estrutural. A mediana +2 de complexidade com IA é uma magnitude potencialmente relevante para uma kata curta, mas o IC exploratório inclui melhora de cinco pontos e piora de quatro; não há precisão para afirmar direção consistente. A duplicação nula

representa empate sob a configuração específica do JSCPD, não prova ausência de repetição conceitual. As diferenças em LOC e MI ajudam a contextualizar tamanho/manutenibilidade, mas não substituem o teste pareado pré-registrado.

Ameaças à validade

- **Interna:** sequência efetiva desviou do contrabalanceamento, especialmente P02, que realizou os três trials Manuais antes dos de IA; P02-K04-ai terminou às 23:59 de 17/09 e P02-K01-ai às 00:10 de 18/09, após o prazo planejado.
- **De construto:** o tratamento IA não foi homogêneo entre Codex e Claude; cinco logs de prompt não puderam ser exportados. RQ2 depende de uma correção de interpretação documentada do coletor.
- **De conclusão:** há pseudorrepliação, três participantes, ausência estrutural e empates totais. Valores de p , tamanhos de efeito e ICs são exploratórios.
- **Externa:** são seis katas curtas, estudantes de uma única turma e ferramentas/versões específicas. Os resultados não se generalizam automaticamente para tarefas industriais, outros modelos ou equipes.
- **De histórico/aprendizagem:** três tentativas IA invalidadas foram excluídas por ausência de interação real; a exposição prévia à kata em uma retentativa ainda pode influenciar o desempenho posterior.

5. Conclusão

Esta primeira versão do relatório consolida um experimento com 18 trials rastreáveis e um pipeline que pode ser reexecutado. A evidência observada favorece o uso de assistente de IA para tempo em sete dos nove pares, não mostra diferença funcional na taxa final de testes e é inconclusiva para qualidade estrutural devido à disponibilidade limitada das métricas. A interpretação mais responsável é local ao experimento: há indícios de menor tempo com IA sob estas condições, sem evidência de ganho funcional adicional e sem precisão suficiente para caracterizar o efeito estrutural.

Os resultados desfavoráveis ou ambíguos foram mantidos: os empates de RQ2, a direção de complexidade potencialmente pior com IA e as ausências de RQ3 não foram ocultados. Uma replicação mais forte precisaria de mais participantes, instrumentos com exportação de prompts verificável, um único assistente/versão, registro de métricas estruturais completo e contrabalanceamento efetivamente seguido.

6. Referências

- LAB02. Metodologia e protocolo pré-registrado (`../../Docs/methodology.md`). Repositório do experimento, 2026.
- LAB02. Dataset processado de trials (`../../data/processed/trials.csv`), resultados estatísticos (`../../data/processed/statistical-results.csv`) e relatório de validação (`../../drafts/data-validation.md`), 2026.
- LAB02. Respostas consolidadas às RQs (`../../drafts/rq-answers.md`), ameaças à validade (`../../drafts/validity-threats.md`), auditoria de execução (`../../Docs/execution-audit.md`) e decisões do protocolo (`../../Docs/protocol-decisions.md`), 2026.
- WILCOXON, Frank. Individual Comparisons by Ranking Methods. *Biometrics Bulletin*, v. 1, n. 6, p. 80–83, 1945.
- ZUSE, Horst. *A Framework of Software Measurement*. Walter de Gruyter, 2013.
- Repositório: <https://github.com/Victorgabrielcruz/lab-medicao-e-experimentacao-de-software>. GitHub Projects: <https://github.com/users/Victorgabrielcruz/projects/6/views/1>.