LAB03 · MEDIÇÃO E EXPERIMENTAÇÃO DE SOFTWARE

# Métricas DORA em 500 repositórios *do GitHub*

O que releases e execuções de CI revelam sobre entrega, e quanto a resposta depende da definição usada.

Víctor G. C. Pereira · Jonathan S. da Silva · Matheus F. de Oliveira  PUC Minas · 2026

RECORTE

# Um ano de entregas públicas, medido pela API

**500**

repositórios elegíveis, entre 1.064 avaliados por estrelas

**12**

meses, de outubro de 2025 a setembro de 2026

**34.255**

releases estáveis tratadas como implantações

**92.890**

episódios de falha de CI no branch principal

`CFR (a)` runs de CI com falha ÷ runs válidos

`CFR (b)` releases seguidas por uma release corretiva em até 7 dias

RQ01–RQ04 · MEDIANAS ENTRE REPOSITÓRIOS

# Ritmo moderado, CI estável e recuperação rápida

Frequência

## 0,48

releases por semana, cerca de duas por mês

Medium é a classe mais comum (49,6%)

Lead time

## 12,6 d

do commit à release, mediana por commit

Low é a classe mais comum (31,8%)

Taxa de falha

## 5,3%

pelas falhas de CI, contra 44% por releases corretivas

só 20,9% recebem a mesma classe nas duas

Recuperação

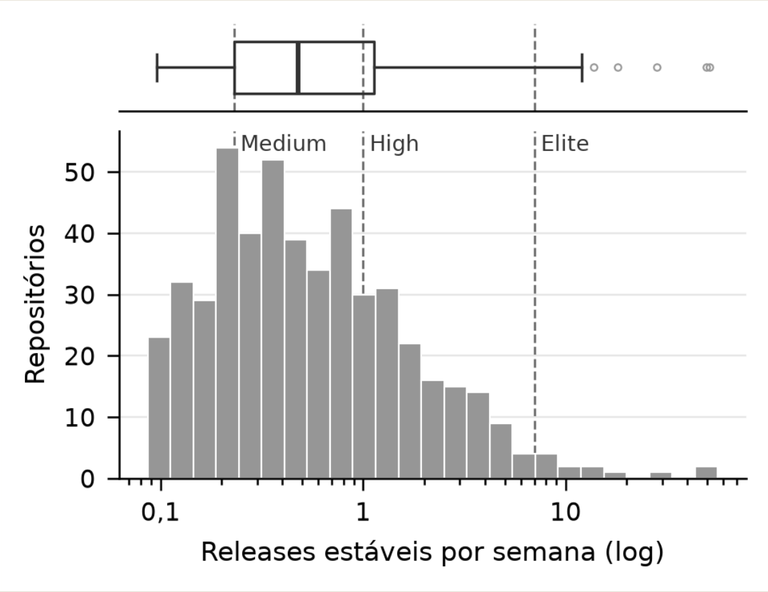
## 2,6 h

da primeira falha ao próximo sucesso no CI

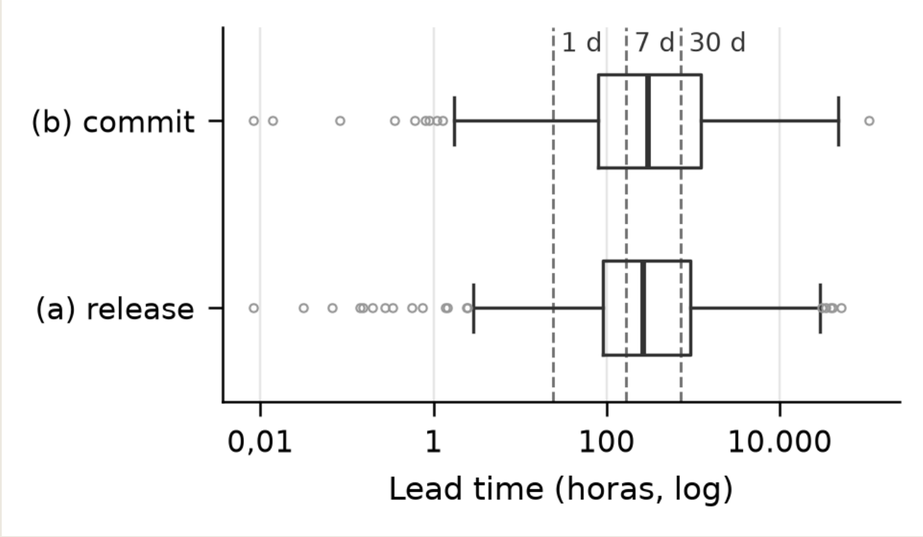
High em 61,0% dos repositórios

RQ01 E RQ02 · DISTRIBUIÇÕES

# Poucos publicam toda semana; lead time disperso



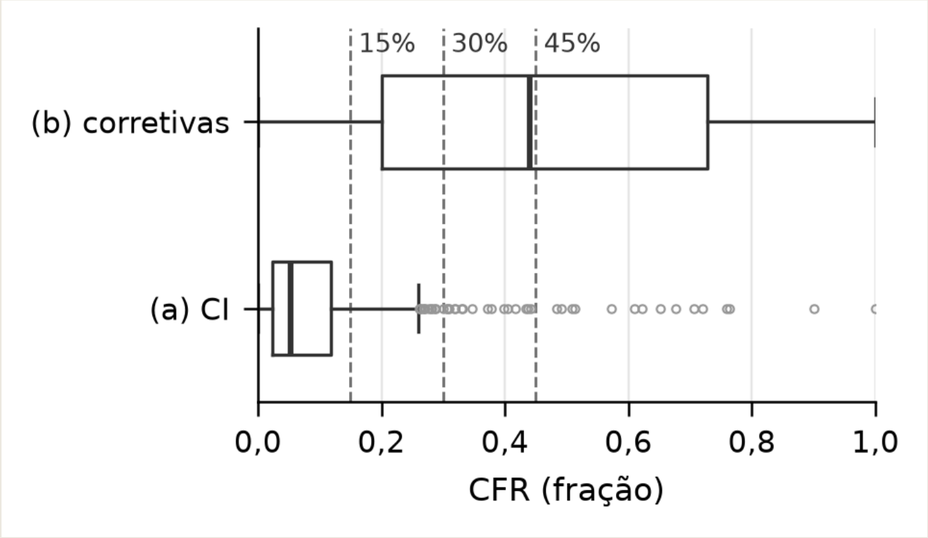

Frequência: cauda longa até 51 releases por semana; 2,4% atingem Elite.



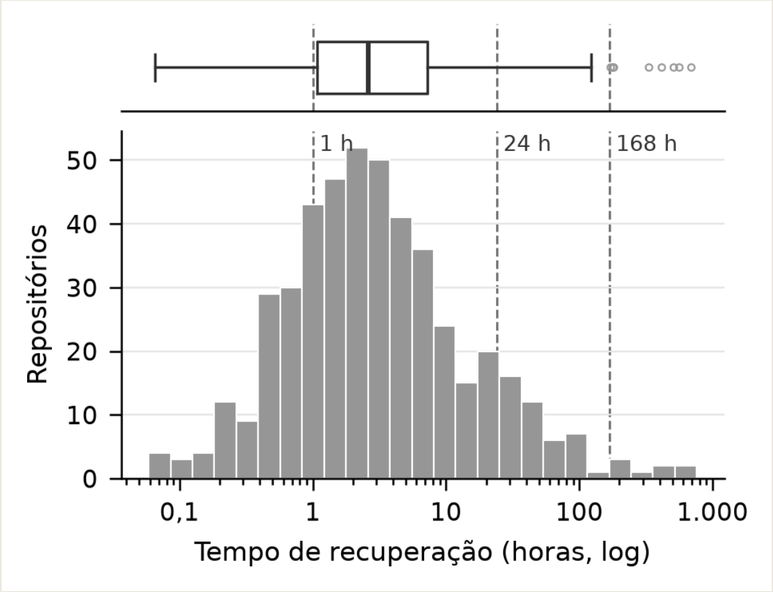

Lead time: a variante por release supera a por commit em 60,7% dos repositórios.

RQ03 E RQ04 · DISTRIBUIÇÕES

# As duas taxas de falha medem coisas diferentes




CFR: 81% são Elite pelo CI, mas 49% são Low por releases corretivas.




Recuperação: maioria entre 1 e 24 horas; só 0,36% dos episódios sem fim.

CLASSE DORA GERAL · REFERÊNCIA C1

# Quase todos ficam no meio da escala

**89,2%**

dos 500 repositórios estão em High ou Medium. Elite e Low, juntos, somam 10,8%.

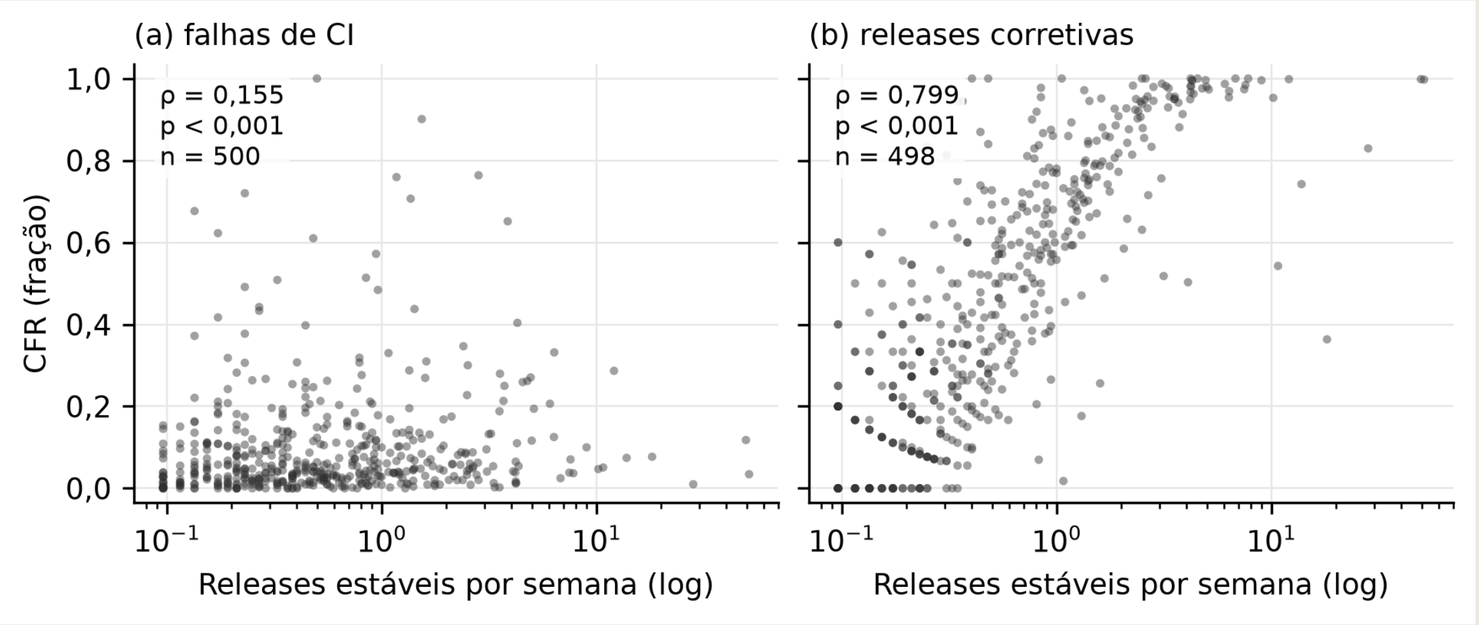


5,6 High · 44,0% Medium · 45,2% 5,2

Elite 5,6% à esquerda · Low 5,2% à direita · mediana das notas de frequência, lead time (b), CFR (a) e recuperação

RQ05 · FREQUÊNCIA × TAXA DE FALHA

# Quem publica mais não falha menos




**ρ = 0,155**

falhas de CI: associação positiva e fraca

**ρ = 0,799**

releases corretivas: forte, mas em parte efeito da definição

RQ06 · QUARTIS DE ESTRELAS, CONTRIBUIDORES E IDADE

# Idade e contribuidores importam; estrelas, não

| $\varepsilon^2$ por métrica | Estrelas | Contrib. | Idade |
|---|---|---|---|
| Frequência | 0,016 | 0,006 | 0,089 * |
| Lead time (a) | 0,003 | 0,149 * | 0,283 * |
| Lead time (b) | 0,002 | 0,218 * | 0,296 * |
| CFR (a) | 0,007 | 0,009 | 0,009 |
| CFR (b) | 0,010 | 0,008 | 0,171 * |
| Recuperação | 0,009 | 0,003 | 0,039 * |

* p < 0,05 após Holm · Kruskal–Wallis · 7 de 18 testes

## Projetos mais novos

publicam mais, têm lead time menor e recuperam mais rápido, mas têm CFR (b) maior

## Menos contribuidores

lead time menor, com efeito grande (δ de Cliff = −0,69)

Nenhum perfil é melhor em todas as métricas.

RQ07 · SENSIBILIDADE ÀS DEFINIÇÕES

# A classe depende de como se mede a falha

**38,3%**

mudam de classe ao trocar só a definição de CFR (κ = 0,56)

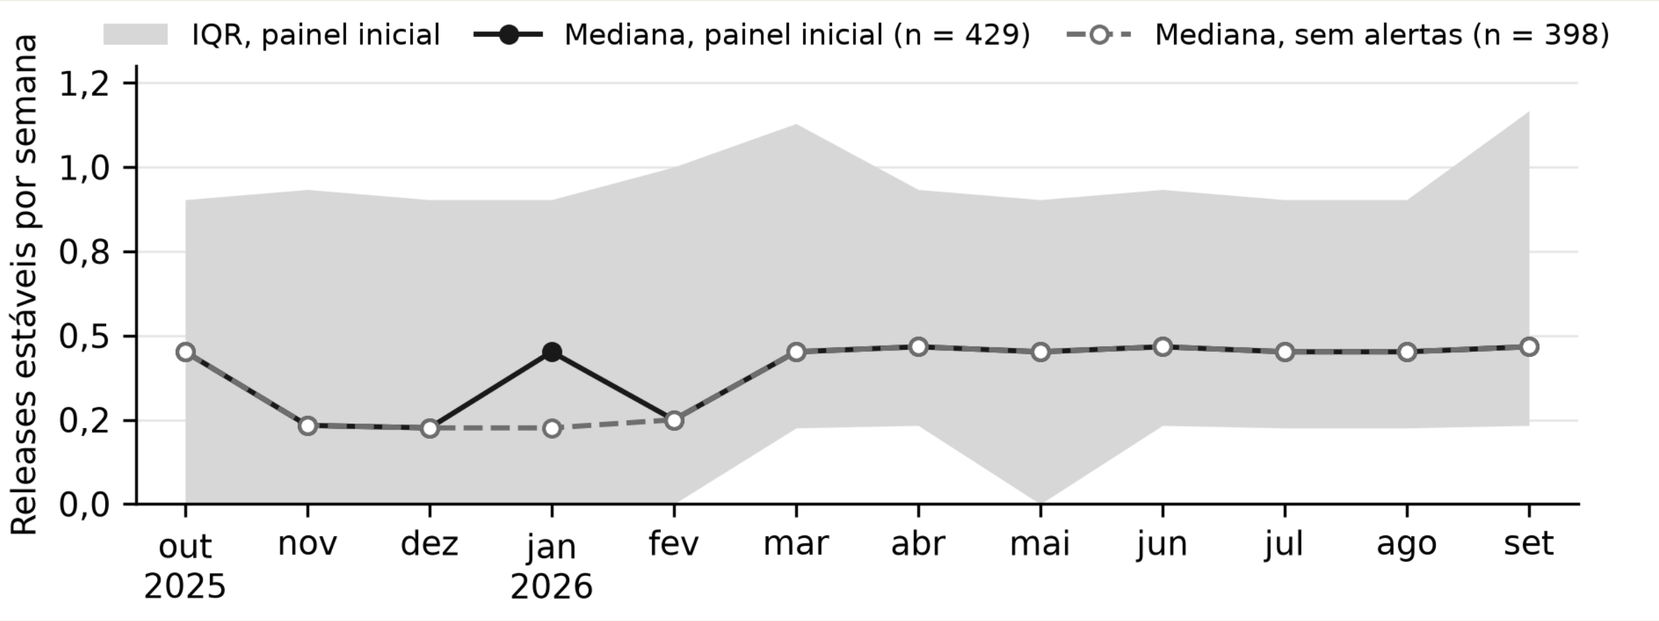
**14,5%**

mudam ao trocar só a variante de lead time (κ = 0,84)

Classe geral em ~467 casos completos · trocando as duas: 42,2% · padrão mantido sem projetos com alertas

RQ08 · EVOLUÇÃO MENSAL (BÔNUS)

# Ritmo estável ao longo do ano




## 0,39 → 0,42

releases por semana, do 1º para o 2º semestre; 228 projetos sobem, 201 caem

HIPÓTESES × RESULTADOS

# Uma confirmada, quatro parciais, duas contrariadas

| RQ | Esperávamos | Encontramos | Veredito |
|---|---|---|---|
| RQ01 | maioria High, 1–3 releases/mês | mediana na faixa, mas Medium lidera | parcial |
| RQ02 | maioria Medium, 1–3 semanas | 12,6 dias, mas Low lidera | parcial |
| RQ03 | CFR de CI entre 10% e 20% | 5,3%; variantes discordam | contrariada |
| RQ04 | poucas horas, maioria High | 2,6 h; High em 61% | confirmada |
| RQ05 | associação negativa | positiva nas duas CFR | contrariada |
| RQ06 | quartis superiores melhores | efeitos mistos; estrelas sem efeito | parcial |
| RQ07 | classe sensível à definição | 38% mudam com a CFR; tags não testadas | parcial |

LIMITES

# O que estes números não dizem

## Proxies

Release não é implantação, e falha de CI não é incidente em produção.

## Amostra

Só projetos populares (30 mil estrelas ou mais) e um único ano.

## Heurística

F1 = 0,933 em 296 releases de 60 projetos; estimativa pontual.

## Causalidade

Associações exploratórias; nenhum fator foi isolado de confundidores.

CONCLUSÕES

# Quatro coisas para levar

01 Projetos populares do GitHub ficam no meio da escala DORA: 89% em High ou Medium.

02 Publicar mais não vem com menos falhas: a associação é positiva.

03 Idade e contribuidores pesam mais que estrelas, sem um perfil melhor em tudo.

04 A definição de falha muda a classe de 38% dos projetos: classes DORA precisam vir com a definição usada.