Mineração de métricas DORA em repositórios populares com GitHub Actions

Víctor G. C. Pereira[1], **Jonathan S. da Silva**[1], **Matheus F. de Oliveira**[1]

[1]Laboratório de Medição e Experimentação de Software
Engenharia de Software – PUC Minas

Abstract. *This study computes the four DORA metrics for 500 popular GitHub repositories using GitHub Actions over twelve months, treating stable releases as deployments and workflow runs as the source of CI failures. Most repositories fall into the High or Medium categories. Deployment frequency and change failure rate are positively correlated, weakly for the CI variant (rho=0.155) and strongly for the corrective-release variant (rho=0.799). Contributors and age are associated with some metrics after Holm correction, with no uniformly superior profile. Changing only the failure-rate definition changes 38.33% of overall categories, against 14.53% for lead time. The corrective-release heuristic reaches F1=0.933 against a manual gold sample.*

Resumo. *Este estudo calcula as quatro métricas DORA para 500 repositórios populares do GitHub com Actions, em doze meses, tratando releases estáveis como implantações e execuções de workflows como fonte de falhas de CI. A maioria dos projetos fica nas classes High ou Medium. Frequência de implantação e taxa de falha têm associação positiva, fraca na variante de CI (rho=0,155) e forte na de releases corretivas (rho=0,799). Contribuidores e idade se associam a algumas métricas após Holm, sem perfil uniformemente superior. Trocar apenas a definição de taxa de falha altera 38,33% das classes gerais, contra 14,53% para o lead time. A heurística de corretivas atinge F1=0,933 contra uma amostra-ouro manual.*

1. Introdução

O programa DORA (*DevOps Research and Assessment*) mede o desempenho de entrega por quatro métricas: frequência de implantação, lead time de mudanças, taxa de falha de mudanças (CFR) e tempo de recuperação [Forsgren et al. 2018], e classifica as equipes em Elite, High, Medium e Low [DevOps Research and Assessment 2021]. Essas classes vêm de questionários. Em projetos de código aberto, releases, commits e execuções de integração contínua são públicos, e o GitHub Actions é amplamente usado [Kinsman et al. 2021, Decan et al. 2022]; calcular as métricas a partir desses dados, porém, exige decidir o que conta como entrega, como medir o lead time e o que é uma falha.

Este trabalho calcula as quatro métricas para 500 repositórios populares que usam GitHub Actions, em doze meses, tratando uma release estável como implantação e as execuções de workflows do branch principal como fonte de falhas. Além da distribuição das métricas e das classes, investigamos a relação entre frequência e CFR, a influência de características dos repositórios e a sensibilidade da classificação às definições operacionais.

1.1. Questões de pesquisa e hipóteses

As hipóteses são expectativas informais registradas no histórico Git antes das análises; as das RQ05 a RQ07 foram formuladas sem consultar resultados.

RQ01 – Frequência de implantação. Maioria High, mediana de uma a três releases por mês, pouquíssimos Elite e cauda longa.

RQ02 – Lead time. Mediana por commit de uma a três semanas (maioria Medium); a variante por release maior que a por commit.

RQ03 – CFR. Mediana de 10% a 20% pelos runs de CI; a variante por releases corretivas com valores e classes diferentes.

RQ04 – Tempo de recuperação. Mediana de algumas horas (maioria High), com cauda longa e episódios abertos no fim da janela.

RQ05 – Frequência e CFR. Associação negativa, mais fraca na CFR de CI, sem interpretação causal.

RQ06 – Características. Quartis superiores de estrelas, contribuidores e idade com melhor desempenho nas quatro métricas.

RQ07 – Definições. Parcela relevante muda de classe ao variar unidade de entrega e variantes de lead time e CFR; maior concordância com pré-releases do que com tags.

Um complemento, registrado após o piloto de coleta e antes das análises de associação, preservou o texto acima e acrescentou: na RQ05, associação fraca ou negativa, com correlações diferentes nas duas CFR; na RQ06, diferenças também por tipo de projeto e heterogeneidade entre métricas, sem atribuir melhor estabilidade a maior tamanho; na RQ07, maior concordância nas classes extremas do que junto aos limites. Esse registro não equivale a uma hipótese anterior a toda observação dos dados.

2. Metodologia

2.1. Seleção, janela e coleta

Os candidatos vêm da Search API do GitHub: repositórios públicos com mil a um milhão de estrelas, sem forks nem arquivados, sem restrição de linguagem. A janela, em UTC, vai de 1/10/2025 (inclusive) a 1/10/2026 (exclusive). Incluímos projetos com workflows próprios em `.github/workflows/`, ao menos cinco releases estáveis (`draft=false`, `prerelease=false`) e cinquenta runs válidos na janela, com coleta de runs completa. Os runs são do default branch, evento `push`; contam como válidos `success`, `failure`, `timed_out` e `startup_failure`, e os demais, como `cancelled`, são ignorados. A coleta mensal subdivide intervalos saturados e usa cache e checkpoints para retomar sem repetir consultas.

Os candidatos foram avaliados na ordem da busca por estrelas até 500 elegíveis (Tabela 1). Nos 561 primeiros avaliados, um único projeto com alto volume de runs (`grafana/grafana`) foi adiado; a coleta foi encerrada com 255 elegíveis e retomada na ordem original, sem adiamento, até 500 elegíveis entre os 1.064 primeiros candidatos, sem alterar janela nem critérios. As decisões estão em `Lab03/docs/`. A amostra não é aleatória.

Tabela 1. Funil de seleção da amostra final

Etapa	Descartados	Restantes
Candidatos da Search API (57 faixas de estrelas)	–	37.383
Avaliados até atingir 500 elegíveis	36.319*	1.064
Com workflows próprios e metadados acessíveis	132	932
Ao menos cinco releases estáveis na janela	363	569
Ao menos cinquenta runs válidos na janela	68	501
Coleta de runs completa	1	500

*Não processados porque a meta foi atingida; não são exclusões.

2.2. Definições operacionais

Frequência (RQ01) é o número de releases estáveis dividido pelas semanas reais da janela. **Lead time (RQ02)** compara releases estáveis consecutivas pela data de autor dos commits novos: a variante (a) toma, por release, a publicação menos o commit mais antigo e usa a mediana entre releases; a (b) usa a mediana de todos os pares commit–release. Primeiras releases sem anterior, releases sem commits novos e comparações indisponíveis ficam fora, com motivo registrado.

CFR (RQ03): a variante (a) é $N_{\text{falhas}}/(N_{\text{falhas}} + N_{\text{sucessos}})$ nos runs válidos; a (b) é a fração de releases seguidas, em até sete dias, por uma release corretiva, identificada por uma heurística de versão patch e termos de commit (v1). Releases dos últimos sete dias ficam censuradas. **Recuperação (RQ04)**: por workflow, a primeira falha após um sucesso abre um episódio e o sucesso seguinte o fecha; o valor do repositório é a mediana das durações recuperadas. Episódios sem sucesso até o fim da janela (censura à direita) e falhas sem sucesso anterior (censura à esquerda) são contados à parte. Métricas sem estimativa ficam nulas, nunca zero, e são resumidas por mediana e IQR com o n válido.

Classes. Usamos os cortes do enunciado: frequência Elite com ao menos sete releases por semana, High com uma por semana e Medium com doze por ano; lead time abaixo de 24, 168 e 720 horas; CFR até 15%, 30% e 45%; recuperação abaixo de 1, 24 e 168 horas. A classe geral é a mediana das notas Low=1 a Elite=4, arredondada para baixo. A referência (C1) usa frequência, lead time (b), CFR (a) e recuperação.

2.3. Validação manual da heurística

Sorteamos 60 dos 255 primeiros elegíveis e cinco releases estáveis de cada (300 pares, semente 42). Três avaliadores registraram tipo de projeto, se as releases são entregas reais e se cada release é corretiva, definida como contendo ao menos uma correção de defeito. O kappa de Fleiss [Fleiss 1971, statsmodels developers 2026] foi 0,875 para tipo, 0,744 para entregas reais e 0,953 para corretiva. Dos 420 itens, 15 divergiram e foram resolvidos em reunião de consenso, que classificou 249 releases como corretivas e 51 como não corretivas. A documentação registra limites de independência entre os avaliadores, de modo que não afirmamos três rotulagens inteiramente cegas. Contra o consenso, a v1 teve precisão 0,891, recall 0,980 e F1 0,933 [scikit-learn developers 2026] em 296 pares; quatro primeiras releases sem predecessora ficaram indeterminadas. Como o F1 superou a meta de 0,70, a regra não foi ajustada.

2.4. Análises estatísticas

Na RQ05, calculamos Spearman bilateral entre frequência e cada CFR, conferido por 99.999 permutações, e repetimos a análise sem os 54 projetos com coleta incompleta ou cálculo parcial. Na RQ06, estrelas, contribuidores e idade foram divididos em quartis de 125 projetos; Kruskal–Wallis compara os quartis em seis métricas, com $\varepsilon^2 = H/(n-1)$, e Mann–Whitney compara os pares, com delta de Cliff ($|\delta|$ de 0,147, 0,33 e 0,474 para pequeno, médio e grande). Holm corrige separadamente os 18 testes globais e os 108 pares, e um par só é relatado se ele e seu teste global passam com $\alpha = 0,05$. Na RQ07, comparamos a classe geral entre combinações de variantes pela proporção de mudanças e pelo kappa de Cohen com pesos quadráticos.

2.5. Replicação cruzada e artefatos

Executamos o pipeline de outro grupo[1] seguindo apenas seu README, com 30 repositórios, e tratamos as issues abertas pelo grupo que replicou o nosso. Código, dataset, dicionário de dados, notebooks e registros estão no repositório[2], e o planejamento, no GitHub Projects[3].

3. Resultados

A Tabela 2 resume as métricas nos 500 repositórios, apenas com valores válidos, e as Figuras 1 e 2 mostram as distribuições.

Tabela 2. Resumo das métricas entre repositórios

RQ	Métrica (unidade)	n	Mediana	IQR (Q1–Q3)
RQ01	Frequência de deploy (releases/semana)	500	0,48	0,23–1,13
RQ02	Lead time (a) por release (horas)	499	268	91–928
RQ02	Lead time (b) por commit (horas)	499	303	79–1.225
RQ03	CFR (a) por runs (fração)	500	0,053	0,023–0,118
RQ03	CFR (b) por releases corretivas (fração)	498	0,440	0,200–0,727
RQ04	Tempo de recuperação (horas)	469	2,6	1,1–7,2

RQ01. A mediana é de 0,48 release estável por semana (cerca de 2,1 por mês), com cauda à direita até 51,3 por semana; 24,0% publicam menos de uma release por mês, 36,6% entre uma e três e 39,4% mais de três. **RQ02.** O lead time (a) tem mediana de 268 horas (11,2 dias), e o (b), de 303 horas (12,6 dias). No mesmo repositório, (a) supera (b) em 303 dos 499 casos (60,7%); a mediana entre repositórios de (b) é maior porque sua cauda superior é mais longa. **RQ03.** A CFR (a) tem mediana de 0,053 e a CFR (b), de 0,440; (a) é menor que (b) em 425 dos 498 pares, e só 104 (20,9%) recebem a mesma classe nas duas variantes. **RQ04.** A mediana de recuperação é de 2,6 horas, com máximo de 693 horas. Dos 92.890 episódios, 330 (0,36%) ficaram censurados à direita, e 683 sequências não têm sucesso anterior; 31 repositórios não têm episódio recuperado e ficam sem valor.

[1] `https://github.com/matheustitton/lab-medicao-experimentacao-6-periodo`, pasta `lab03-metricas-dora`, commit `9ba3443`.

[2] `https://github.com/Victorgabrielcruz/lab-medicao-e-experimentacao-de-software`, pasta `Lab03`.

[3] `https://github.com/users/Victorgabrielcruz/projects/7`

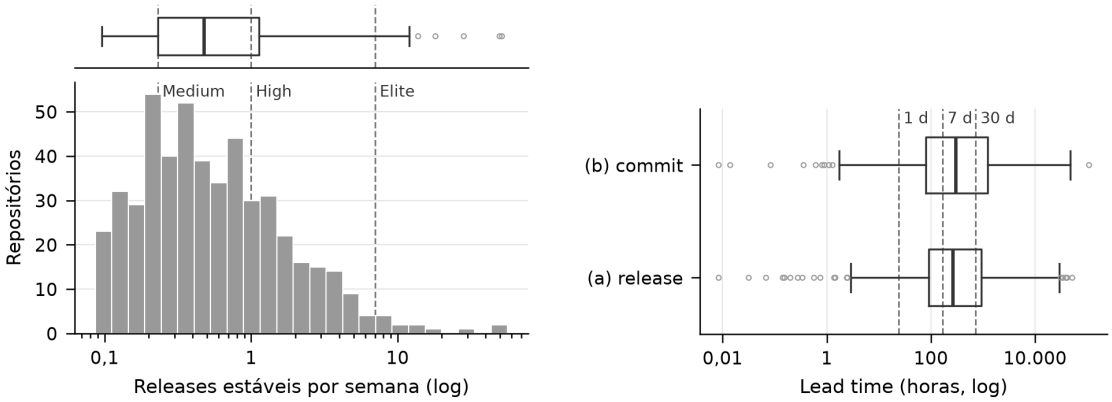


Figura 1. Frequência de deploy (esquerda) e lead time por variante (direita), em escala logarítmica; linhas tracejadas marcam os cortes DORA e os bigodes vão a 1,5 IQR na escala log

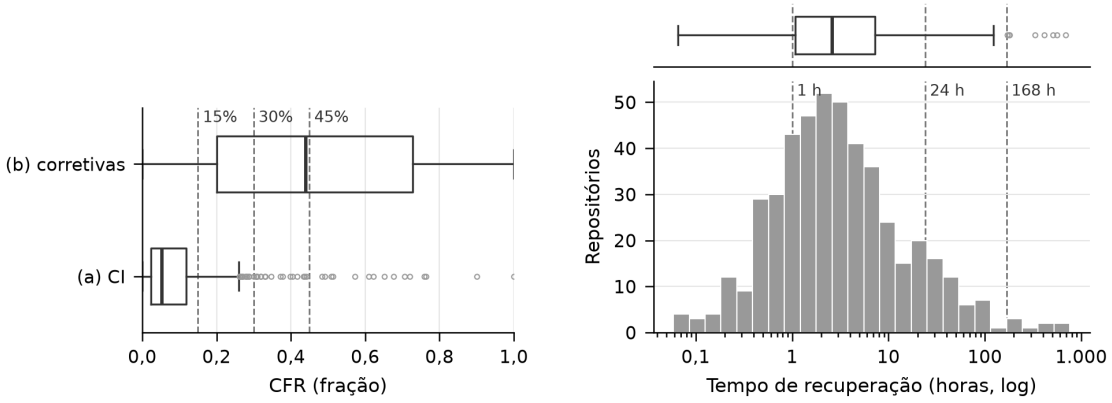


Figura 2. CFR por variante (esquerda) e tempo de recuperação por repositório, em escala logarítmica (direita); linhas tracejadas marcam os cortes DORA e os bigodes vão a 1,5 IQR na escala do eixo

Classes. Na referência C1 (Tabela 3), 89,2% dos repositórios ficam em High ou Medium na classe geral. A frequência concentra-se em Medium, a CFR (a) em Elite e a recuperação em High; o lead time se divide entre High, Medium e Low, e a CFR (b) concentra-se em Low.

3.1. RQ05 – Frequência de deploy e taxa de falha

A associação de Spearman é positiva nas duas variantes: $\rho = 0,155$ para a CFR (a) ($n = 500$, $p = 0,0005$) e $\rho = 0,799$ para a CFR (b) ($n = 498$, $p < 10^{-100}$); as permutações dão $p = 0,00054$ e $p = 0,00002$. Sem os 54 projetos com alertas de qualidade, os valores são $\rho = 0,115$ ($n = 446$, $p = 0,015$) e $\rho = 0,778$ ($n = 444$). A análise é associativa (Figura 3).

3.2. RQ06 – Comparações por fatores

Após Holm, sete dos 18 testes globais mantêm diferença (Tabela 4); nenhuma métrica difere por quartil de estrelas. Entre os 108 pares, 27 passam pela correção. Nos extremos (Q1 contra Q4), projetos com menos contribuidores têm lead times menores ($\delta = -0,580$

Tabela 3. Distribuição nas classes DORA de referência (% dos 500 repositórios)

Métrica	Elite	High	Medium	Low	Sem classe
Frequência de deploy	2,4	24,0	49,6	24,0	0,0
Lead time (a)	12,8	25,6	30,2	31,2	0,2
Lead time (b)	11,2	27,0	29,8	31,8	0,2
CFR (a)	81,0	12,4	3,6	3,0	0,0
CFR (b)	18,8	18,2	13,6	49,0	0,4
Tempo de recuperação	22,6	61,0	8,6	1,6	6,2
Geral C1: LT (b) + CFR (a)	5,6	44,0	45,2	5,2	0,0

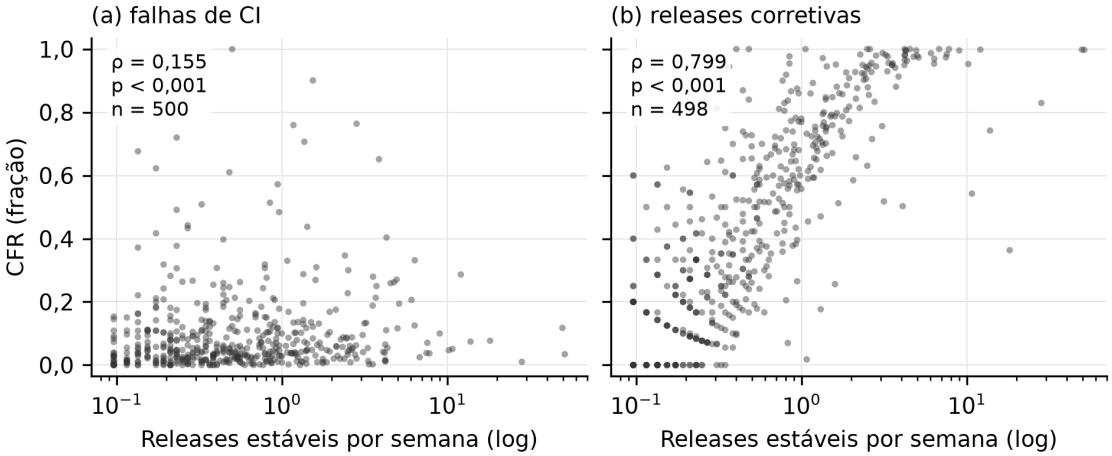


Figura 3. Frequência de deploy, em escala logarítmica, e CFR por variante; ρ, p e n correspondem aos pares válidos de cada painel

e $-0,686$, grandes). Projetos mais novos publicam com mais frequência ($\delta = 0,409$, médio), têm lead times menores ($\delta = -0,746$ e $-0,763$) e recuperação menor ($\delta = -0,267$, pequeno), mas CFR (b) maior ($\delta = 0,575$). Nenhum perfil é superior em todas as métricas.

Tabela 4. RQ06: ε^2 dos testes de Kruskal–Wallis por fator; * indica $p_{\mathrm{Holm}} < 0,05$ na família de 18

Métrica	n	Estrelas	Contribuidores	Idade
Frequência	500	0,016	0,006	0,089*
Lead time (a)	499	0,003	0,149*	0,283*
Lead time (b)	499	0,002	0,218*	0,296*
CFR (a)	500	0,007	0,009	0,009
CFR (b)	498	0,010	0,008	0,171*
Recuperação	469	0,009	0,003	0,039*

3.3. RQ07 – Sensibilidade às definições operacionais

Fixando frequência, recuperação, janela e cortes, variamos lead time e CFR (Tabela 5). Trocar só a CFR muda 38,33% das classes gerais nos casos completos, contra 14,53% ao trocar só o lead time. O padrão se mantém na população comum de 467 projetos, sem os projetos com alertas (14,29%, 37,23% e 41,29%) e com as notas parciais dos 500 (16,0%,

37,4% e 41,6%). Mesmo $\kappa_w = 0,841$ acompanha 68 trocas de classe. A unidade de entrega não foi variada: pré-releases e tags ficaram fora das análises.

Tabela 5. RQ07: mudança da classe geral e kappa quadrático em casos completos

Par	Variantes trocadas	n	Mudança (%)	κ_w
C1×C2	lead time (b)→(a)	468	14,53	0,841
C1×C3	CFR (a)→(b)	467	38,33	0,564
C2×C3	ambas	467	42,18	0,449

3.4. RQ08 – Evolução temporal (bônus)

Como análise exploratória, contamos as 34.255 releases estáveis por mês nos 429 projetos existentes no início da janela. As medianas mensais variam de 0,226 a 0,467 release por semana; do primeiro para o segundo semestre, a mediana passa de 0,385 para 0,421, com 228 projetos aumentando e 201 diminuindo (Figura 4). As medianas oscilam entre valores equivalentes a uma e duas releases por mês. É a descrição de um único ano, sem teste de tendência.

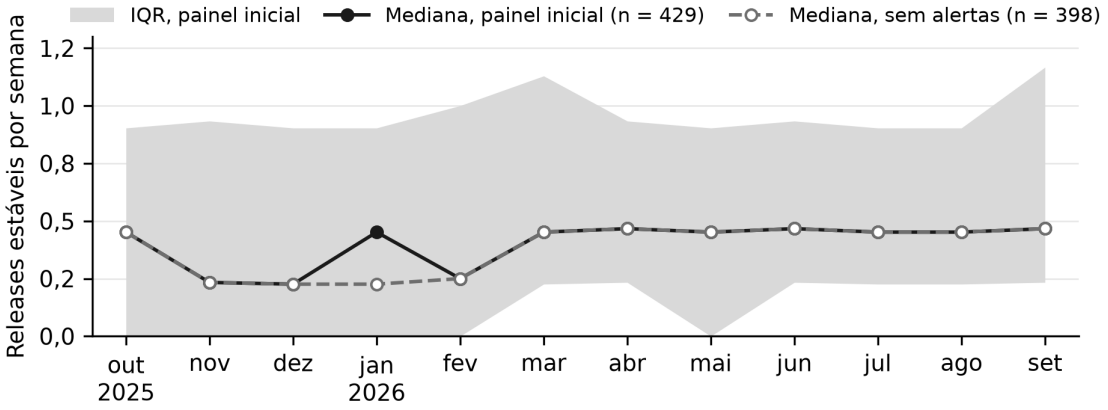


Figura 4. Frequência mensal de releases estáveis por repositório: mediana e IQR no painel de 429 projetos existentes no início da janela e mediana dos 398 sem alertas de qualidade; as duas medianas coincidem, exceto em janeiro de 2026

3.5. Replicação cruzada

O pipeline do outro grupo terminou com 30 repositórios em cerca de 77 minutos, após uma pausa e retomada pelo mesmo comando; 28 deles estão no dataset publicado pelo grupo (237 projetos). Registramos seis problemas, entre eles instruções de ambiente incompatíveis com o Windows, log silencioso por até 17 minutos e sobrescrita de saídas versionadas. A comparação por métrica não foi realizada, e não foi possível abrir issues no repositório do grupo autor. No sentido inverso, as quatro issues recebidas (#251 a #254), sobre documentação, codificação em Windows, tamanho do repositório e espera após HTTP 403, foram corrigidas, verificadas por 1.199 testes e registradas no Project. Os registros estão em `Lab03/replicacao/`.

4. Discussão e ameaças à validade

4.1. Hipóteses e resultados

Os julgamentos abaixo são descritivos, não aceitações formais por testes de nulidade, e consideram as duas redações de RQ05–RQ07.

RQ01, parcial. A mediana de 2,1 releases por mês está na faixa prevista, mas só 36,6% dos projetos estão nela e Medium (49,6%) supera High (24,0%): o corte de High exige uma release por semana. Elite raro e cauda longa confirmam-se. **RQ02, parcial.** A mediana por commit (12,6 dias) está na faixa prevista, mas Low (31,8%) é mais frequente que Medium (29,8%); (a) supera (b) em 60,7% dos pares, como esperado. **RQ03, magnitude contrariada.** A CFR (a), de 5,3%, fica abaixo dos 10–20% previstos; a discordância entre variantes confirma-se. **RQ04, compatível.** Poucas horas, maioria High, cauda longa e censura confirmam-se para a recuperação do CI. **RQ05, direção contrariada.** As associações são positivas, não negativas; a menor na CFR de CI é compatível com a expectativa relativa. Para (b), publicar mais aumenta as oportunidades de uma corretiva surgir nos sete dias seguintes, o que é efeito da definição, não evidência de mais incidentes. **RQ06, superioridade uniforme não sustentada.** Estrelas não diferem após correção, e quartis superiores de contribuidores e idade têm lead times maiores; só a CFR (b) favorece projetos mais antigos. A heterogeneidade prevista no complemento confirma-se; tipo de projeto não foi testado nos 500. **RQ07, parcial.** A classe depende das variantes, sobretudo da CFR; pré-releases, tags e classes extremas não foram testadas.

4.2. Relação com a literatura e implicações

O DORA observa equipes que combinam alta frequência e baixa taxa de falha [DevOps Research and Assessment 2021]. A associação positiva da RQ05 não o refuta: aqui a unidade é o repositório e as falhas são proxies de CI ou corretivas, não degradações em produção. A sensibilidade às definições é coerente com a adaptação do benchmarking a projetos abertos, que separa releases de implantações [Sánchez Ruiz et al. 2023]. Como só incluímos usuários de Actions, não atribuímos os resultados à ferramenta [Kinsman et al. 2021]. Para mantenedores, frequência, lead time e estabilidade devem ser acompanhados juntos e com definições constantes; estrelas, contribuidores e idade não são metas de desempenho. Para a pesquisa, classes DORA devem vir com valores contínuos, n, exclusões e variantes.

4.3. Ameaças à validade

Construto. Uma release aproxima uma implantação; a amostra-ouro julgou as releases como entregas reais em 59 dos 60 projetos. A data de autor pode ser reescrita por rebase. Falhas de CI incluem testes instáveis e erros de configuração, e a CFR (b) depende da heurística; por isso reportamos as duas variantes. A recuperação mede o CI, não a restauração de serviço. As classes dependem dos cortes e das variantes, como mostra a RQ07.

Interna. Limites da API e interrupções podem deixar dados incompletos; mitigamos com coleta mensal subdividida, cache, checkpoints e diagnósticos (13 projetos com alguma coleta incompleta e 52 com cálculo parcial), sem imputar zeros. Metadados refletem o estado observado na coleta. A ordem de coleta adiou um projeto nos 561 primeiros avaliados, sem mudar critérios. A CFR (b) herda os erros da heurística, avaliada em uma

amostra de 60 projetos com limites documentados de independência dos avaliadores; a exclusão de episódios censurados tende a subestimar recuperações longas.

Externa. Os 500 projetos têm ao menos 30.088 estrelas (mediana de 45.049) e passaram por filtros de Actions, releases e runs; projetos privados, pouco conhecidos, sem releases ou com outro CI ficam fora. Um único ano não captura variações entre anos. Mitigamos declarando o funil sem relaxar critérios e restringindo as conclusões a esse recorte; a configuração versionada permite repetir a coleta com outra janela.

Conclusão. O tamanho da amostra não veio de análise de poder. Com 500 projetos, efeitos fracos já são significativos (CFR (a): $\rho = 0,155$), e o n efetivo varia por métrica, de 469 a 500, o que reduz o poder dos contrastes por quartil. Por isso interpretamos ρ, ε^2 e δ, usamos permutações, Holm e a repetição sem projetos com alertas. A F1 vem de 296 pares e é uma estimativa pontual. As hipóteses complementares foram registradas após o piloto, e as combinações da RQ07, após a coleta. A replicação cruzada não incluiu comparação numérica, o que limita a evidência de reprodutibilidade.

5. Conclusão

Calculamos as métricas DORA para 500 repositórios populares com GitHub Actions, com um pipeline reproduzível que preserva ausências, censuras e diagnósticos. A maioria dos projetos fica em High ou Medium; a CFR de CI é baixa, enquanto a CFR por releases corretivas é alta e discorda dela na maioria dos casos. Frequência e CFR têm associação positiva, mais forte na variante de corretivas. Contribuidores e idade se associam a algumas métricas, sem um perfil superior em todas, e estrelas não mostram diferença após correção. Trocar apenas a definição de CFR altera 38,33% das classes gerais, contra 14,53% ao trocar apenas o lead time. Esses resultados são exploratórios e restritos ao recorte estudado. Trabalhos futuros podem variar a unidade de entrega, comparar os proxies com incidentes reais e analisar o tipo de projeto em toda a amostra.

Referências

Decan, A., Mens, T., Mazrae, P. R., and Golzadeh, M. (2022). On the use of github actions in software development repositories. In *Proceedings of the IEEE International Conference on Software Maintenance and Evolution (ICSME)*.

DevOps Research and Assessment (2021). Accelerate state of devops 2021. Technical report, Google Cloud.

Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382.

Forsgren, N., Humble, J., and Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps: Building and Scaling High Performing Technology Organizations*. IT Revolution Press.

Kinsman, T., Wessel, M., Gerosa, M. A., and Treude, C. (2021). How do software developers use github actions to automate their workflows? In *Proceedings of the 18th International Conference on Mining Software Repositories (MSR)*.

Sánchez Ruiz, J. M., Domínguez Mayo, F. J., Oriol, X., Crespo, J. F., Benavides, D., and Teniente, E. (2023). A benchmarking proposal for DevOps practices on open

source software projects. https://arxiv.org/abs/2304.14790. Preprint arXiv:2304.14790, consultado em 22 de outubro de 2026.

scikit-learn developers (2026). Precision, recall, f-measure and support. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.precision_recall_fscore_support.html. Documentação consultada em 15 de outubro de 2026.

statsmodels developers (2026). Fleiss' kappa and aggregation of raters. https://www.statsmodels.org/stable/generated/statsmodels.stats.inter_rater.fleiss_kappa.html. Documentação consultada em 15 de outubro de 2026.